

En este notebook vamos a hacer un pequeño ejercicio en el que **conectaremos Hadoop con ElasticSearch**. En concreto, **haremos una conexión entre Hive y un índice (o index) de ElasticSearch**

Conectar Hadoop y ElasticSearch, puede ser beneficioso en varios escenarios. Por ejemplo:

- **Análisis de Datos en Tiempo Real:** Elasticsearch permite realizar búsquedas y análisis de texto completo de manera eficiente. Al conectar Hadoop o Hive con Elasticsearch, se pueden analizar datos en tiempo real y obtener resultados rápidos en consultas complejas sobre grandes volúmenes de datos indexados en Elasticsearch.
- **Integración de Fuentes de Datos:** Hadoop se utiliza comúnmente para procesar y almacenar grandes volúmenes de datos estructurados y no estructurados. Conectarlo con Elasticsearch nos permitirá integrar datos almacenados en Hadoop con Elasticsearch para facilitar el acceso y la búsqueda rápida de información.
- **Indexación de Datos:** Podemos usar Hadoop para preparar y procesar datos antes de indexarlos en Elasticsearch. Esto es útil cuando debemos aplicar transformaciones complejas o agregaciones masivas antes de almacenar datos para análisis y búsqueda.
- **Consultas y Visualizaciones Avanzadas:** Elasticsearch proporciona capacidades avanzadas para consultas y visualizaciones de datos. Al conectarlo con Hadoop o Hive, podemos ejecutar consultas complejas sobre grandes conjuntos de datos y obtener resultados rápidos y precisos, lo cual es útil para análisis de negocios, monitoreo en tiempo real, etc.
- **Búsqueda y Recuperación de Información:** Utilizar Hadoop para procesar y preparar datos que luego se indexan en Elasticsearch, puede mejorar significativamente la capacidad de búsqueda y recuperación de información, permitiendo a los usuarios finales encontrar rápidamente la información relevante que necesitan.

Elasticsearch for Apache Hadoop™



elastic{ON}¹⁵

CC-BY-ND 4.0

Si a esto le agregamos además la visualización con **Kibana**, obtenemos una potencia tremenda para la obtención, procesado y gestión completa de **Big Data**.

INSTRUCCIONES DE ENTREGA

Cada uno de los apartados de la práctica tiene un entregable, que en todos los casos es una captura de pantalla del resultado del proceso llevado a cabo en la parte (se indica cómo debe ser al final de cada apartado).

Estas capturas de pantalla deben ser colocadas en un archivo de texto (word, excel) que será convertido finalmente a pdf para su entrega.

El producto entregable será un único documento en formato pdf conteniendo las capturas de las diferentes partes de la práctica.

PARTE 1 - Configuración ES-Hadoop

Para configurar nuestro **ES-Hadoop**, vamos a necesitar herramientas que ya hemos utilizado a lo largo del módulo.

- Un cluster standalone o standard en Dataproc
- Un ELK (Elastic Search, Logstash, Kibana) de Elasticsearch

(Logstash es una herramienta de procesamiento de datos que permite la ingestión desde múltiples fuentes en Elasticsearch. Puede parsear, enriquecer y transformar los datos antes de enviarlos a ES para su almacenamiento y análisis)

También tendremos que hacer algunos cambios en la configuración previamente, como instalar librerías de soporte en Hadoop y poner elasticsearch en modo inseguro para esta prueba.

a) Creamos un cluster Hadoop

b) Cargamos en el cluster los jars de configuración de elasticsearch-hadoop y commons-httpclient

- Descarguemos estos jars:

<https://artifacts.elastic.co/downloads/elasticsearch-hadoop/elasticsearch-hadoop-8.14.1.zip>

https://repo1.maven.org/maven2/commons-httpclient/commons-httpclient/3.1/commons-httpclient-3.1.jar

- Creamos un nuevo bucket para nuestro ES-Hadoop
 - Extraemos el contenido del zip, y **subimos ambos jar a nuestro bucket** en google storage
- OJO** 👁️ Subamos al bucket el archivo **elasticsearch-hadoop-8.14.1.jar** del zip, que se encuentra dentro de la carpeta **dist** del zip de elasticsearch-hadoop, no toda la carpeta. Podemos colocarlos en la ruta como se muestra en la siguiente imagen:

Bucket details

bucket-para-elastic

Location: southamerica-west1 (Santiago) | Storage class: Standard | Public access: Not public | Protection: Soft Delete

OBJECTS | CONFIGURATION | PERMISSIONS | PROTECTION | LIFECYCLE | OBSERVABILITY | INVENTORY REPORTS | OPERATIONS

Buckets > bucket-para-elastic > jars > elastic

UPLOAD FILES | UPLOAD FOLDER | CREATE FOLDER | TRANSFER DATA | MANAGE HOLDS | EDIT RETENTION | DOWNLOAD | DELETE

Filter by name prefix only | Filter | Filter objects and folders | Show Live objects only

☐	Name	Size	Type	Created	Storage class	Last modified	Public access	
☐	commons-httpclient-3.1.jar	297.9 KB	application/octet-stream	Jun 29, 2024, 6:58:27 PM	Standard	Jun 29, 2024, 6:58:27 PM	Not public	Download
☐	elasticsearch-hadoop-8.14.1.jar	2.1 MB	application/octet-stream	Jun 29, 2024, 6:56:04 PM	Standard	Jun 29, 2024, 6:56:04 PM	Not public	Download

c) Descargamos los jar desde el bucket al filesystem del cluster


Para eso tenemos que abrir la consola del nodo maestro del cluster y subirlos con los siguientes comandos:

```
gsutil cp gs://bucket-para-elastic/jars/elastic/elasticsearch-hadoop-8.14.1.jar .
```

gsutil cp gs://bucket-para-elastic/jars/elastic/commons-httpclient-3.1.jar .

Con el nombre de vuestro bucket, claro.

ENTREGABLE PARTE 1: Captura de pantalla de la consola SSH del cluster Hadoop una vez finalizada la configuración y carga.



```
SSH en el navegador
jbdmadrid@cluster-practica-hadoop-m:~$ gsutil cp gs://bucket-practica-elastic/jars/elastic/elasticsearch-hadoop-8.14.1.jar .
-bash: gsutil cp gs://bucket-practica-elastic/jars/elastic/elasticsearch-hadoop-8.14.1.jar .: No such file or directory
jbdmadrid@cluster-practica-hadoop-m:~$ gsutil cp gs://bucket-practica-elastic/jars/elastic/*.jar .
-bash: gsutil cp gs://bucket-practica-elastic/jars/elastic/*.jar .: No such file or directory
jbdmadrid@cluster-practica-hadoop-m:~$ ls
snap
jbdmadrid@cluster-practica-hadoop-m:~$ gsutil cp gs://bucket-practica-elastic/jars/elastic/*.jar .
-bash: gsutil cp gs://bucket-practica-elastic/jars/elastic/*.jar: No such file or directory
jbdmadrid@cluster-practica-hadoop-m:~$ gsutil cp gs://bucket-practica-elastic/jars/elastic/*.jar .
Copying gs://bucket-practica-elastic/jars/elastic/commons-httpclient-3.1.jar...
Copying gs://bucket-practica-elastic/jars/elastic/elasticsearch-hadoop-8.14.1.jar...
 / [2 files] [ 2.4 MiB / 2.4 MiB]
Operation completed over 2 objects/2.4 MiB.
jbdmadrid@cluster-practica-hadoop-m:~$ ls
commons-httpclient-3.1.jar  elasticsearch-hadoop-8.14.1.jar  snap
jbdmadrid@cluster-practica-hadoop-m:~$
```

PARTE 2 - Configuración server Elasticsearch

- Creamos una nueva VM para elastic
- Configuramos la instancia de Elasticsearch

¿Qué más necesitaremos? 🤔

- Crear las reglas de firewall! -> Necesitamos abrir la comunicación al puerto 9200 y 5601 para acceder desde el cluster Hadoop y desde nuestro equipo local.

Una vez tengamos todo esto, podemos comprobar desde el cluster ue tenemos acceso a la máquina Elastic.

ENTREGABLE PARTE 2: Captura de pantalla de la consola del server Elastic donde se vea la configuración de elastic, desde 'Enable security features' hasta el final (el fichero elasticsearch.yml) abierta.(Recordad: Comando sudo cat...)

```
GNU nano 6.2 /etc/elasticsearch/elasticsearch.yml
# ----- Various -----
# Allow wildcard deletion of indices:
#
#action.destructive_requires_name: false
# ----- BEGIN SECURITY AUTO CONFIGURATION -----
#
# The following settings, TLS certificates, and keys have been automatically
# generated to configure Elasticsearch security features on 14-03-2026 11:26:48
#
# -----
# Enable security features
xpack.security.enabled: false
xpack.security.enrollment.enabled: true
# Enable encryption for HTTP API client connections, such as Kibana, Logstash, and Agents
xpack.security.http.ssl:
  enabled: false
  keystore.path: certs/http.p12
# Enable encryption and mutual authentication between cluster nodes
xpack.security.transport.ssl:
  enabled: true
  verification_mode: certificate
  keystore.path: certs/transport.p12
  truststore.path: certs/transport.p12
# Create a new cluster with the current node only
# Additional nodes can still join the cluster later
cluster.initial_master_nodes: ["instance-practica-es"]
# Allow HTTP API connections from anywhere
# Connections are encrypted and require user authentication
http.host: 0.0.0.0
# Allow other nodes to join the cluster from anywhere
# Connections are encrypted and mutually authenticated
#transport.host: 0.0.0.0
```

**PARTE 3 - Configuración en Cluster Hadoop de
Conexión con ES**

Una vez que ya hemos creado y configurado el server Elasticsearch y tenemos los ficheros en el master del cluster Dataproc, ya podemos **cargar los jars en la configuración de HIVE**. Para ello, debemos modificar el hive-site.xml.

```
sudo sed -i '$d' /etc/hive/conf.dist/hive-site.xml
```

```
sudo sed -i '$a \ <property>\n  <name>es.nodes</name>\n  <value>AQUÍ LA IP DE ELASTIC</value>\n </property>\n' /etc/hive/conf.dist/hive-site.xml
```

```
sudo sed -i '$a \ <property>\n  <name>es.port</name>\n  <value>9200</value>\n</property>\n' /etc/hive/conf.dist/hive-site.xml
```

```
sudo sed -i '$a \ <property>\n  <name>es.nodes.wan.only</name>\n<value>true</value>\n </property>\n' /etc/hive/conf.dist/hive-site.xml
```

```
sudo sed -i '$a \ <property>\n  <name>hive.aux.jars.path</name>\n<value>/usr/lib/hive/lib/elasticsearch-hadoop-8.14.1.jar,/usr/lib/hive/lib/commons-httpclient-3.1.jar</value>\n </property>\n</configuration>' /etc/hive/conf.dist/hive-site.xml
```

```
sudo cp elasticsearch-hadoop-8.14.1.jar /usr/lib/hive/lib/
```

```
sudo cp commons-httpclient-3.1.jar /usr/lib/hive/lib/
```

¿Qué hacen exactamente estos comandos?

Utilizan el editor de flujo **sed** para transformar el fichero hive-site.xml, con la opción **-i**, que modifica el archivo "in-place".

En el primer comando, '\$d' representa el final del archivo. Elimina la última línea.

En el segundo comando, '\$a...' indica añadir una línea al final del archivo. La línea que añadimos, es el cambio en la configuración, diciéndole los jars que tiene que utilizar ahora.

[/etc/hive/conf.dist/hive-site.xml](#) es la ruta donde se encuentra el archivo de configuración (esto puede variar).

El último comando, colocará los jar de elasticsearch y kibana en la ruta correcta.

👉👉 Tras esto, debemos **reiniciar hive** para que se apliquen los cambios!!

ENTREGABLE PARTE 3: Captura de pantalla del proceso de configuración en Cluster Hadoop de Conexión con ES completo.


```

Last login: Sat Mar 14 11:03:42 2026 from 35.235.249.250
jbdmadrid@cluster-practica-hadoop-m:~$ ls /etc/h
hadop/      hive/       host.conf   hosts        hosts.deny
hdparm.conf hive-hcatalog/ hostname    hosts.allow
jbdmadrid@cluster-practica-hadoop-m:~$ ls /etc/h
hadop/      hive/       host.conf   hosts        hosts.deny
hdparm.conf hive-hcatalog/ hostname    hosts.allow
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$d' /etc/hive/conf.dist/hive-site.xml
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>es.nodes</name>\n    <value>10.128.0.12</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
-bash: sudo sed -i '$a \ <property>\n    <name>es.nodes</name>\n    <value>10.128.0.12</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml: No such file or directory
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>es.nodes</name>\n    <value>10.128.0.12</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
sed: -e expression #1, char 5: unknown command: '<'
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>es.nodes</name>\n    <value>10.128.0.12</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>es.port</name>\n    <value>9200</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>es.nodes.wan.only</name>\n    <value>true</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
jbdmadrid@cluster-practica-hadoop-m:~$ sudo sed -i '$a \ <property>\n    <name>hive.aux.jars.path</name>\n    <value>/usr/lib/hive/lib/elasticsearch-hadoop-8.14.1.jar,/usr/lib/hive/lib/commons-httpclient-3.1.jar</value>\n  </property>\n' /etc/hive/conf.dist/hive-site.xml
jbdmadrid@cluster-practica-hadoop-m:~$ sudo cp elasticsearch-hadoop-8.14.1.jar /usr/lib/hive/lib/
jbdmadrid@cluster-practica-hadoop-m:~$ sudo cp commons-httpclient-3.1.jar /usr/lib/hive/lib/
jbdmadrid@cluster-practica-hadoop-m:~$ sudo systemctl restart hive-metastore
jbdmadrid@cluster-practica-hadoop-m:~$ sudo systemctl restart hive-server2
jbdmadrid@cluster-practica-hadoop-m:~$ cat /etc/hive/conf.dist/hive-site.xml

```

```

</property>
<property>
  <name>hive.execution.engine</name>
  <value>tez</value>
</property>
<property>
  <name>hive.server2.builtin.udf.blacklist</name>
  <value>reflect,reflect2</value>
</property>
<property>
  <name>hive.exec.local.scratchdir</name>
  <value>/var/tmp/hive-scratch</value>
</property>
<property>
  <name>hive.exec.scratchdir</name>
  <value>/var/tmp/hive-scratch</value>
</property>
<property>
  <name>hive.metastore.uris</name>
  <value>thrift://cluster-practica-hadoop-m:9083</value>
</property>
<property>
  <name>hive.user.install.directory</name>
  <value>${hadoop.tmp.dir}/hive/user-install-dir</value>
</property>
<property>
  <name>hive.exec.input.listing.max.threads</name>
  <value>20</value>
</property>
<property>
  <name>hive.fetch.task.conversion</name>
  <value>minimal</value>
</property>
<property>
  <name>es.nodes</name>
  <value>10.128.0.12</value>
</property>

<property>
  <name>es.port</name>
  <value>9200</value>
</property>

<property>
  <name>es.nodes.wan.only</name>
  <value>true</value>
</property>

<property>
  <name>hive.aux.jars.path</name>
  <value>/usr/lib/hive/lib/elasticsearch-hadoop-8.14.1.jar,/usr/lib/hive/lib/commons-httpclient-3.1.jar</value>
</property>
</configuration>
jbdmadrid@cluster-practica-hadoop-m:~$ █

```

PARTE 4 - A conectar datos!

No olvidemos tener los Firewall correctamente configurados (debe estar hecho desde la parte 2)

Ahora, desde nuestro **server Elasticsearch**, vamos a crear un índice sobre el que después trabajaremos en el cluster Hadoop:

```
curl -X POST "localhost:9200/alumnos/_doc/6" -H 'Content-Type: application/json' -d'
```

```
{  
  
  "title": "New Document",  
  
  "content": "This is a new document for the master class",  
  
  "tag": ["general", "testing"]  
}
```

,

Finalmente, en **nuestro cluster Hadoop**, vamos a agregar documentos al index alumnos recién creado:

```
curl -X POST "IP-SERVER-ELASTICSEARCH:9200/_bulk" -H 'Content-Type:  
application/json' -d'
```

```
{ "index": { "_index": "alumnos", "_id": "3" } }
```

```
{ "id": 3, "name": "Carlos", "last_name": "González" }
```

```
{ "index": { "_index": "alumnos", "_id": "4" } }
```

```
{ "id": 4, "name": "María", "last_name": "López" }
```

```
{ "index": { "_index": "alumnos", "_id": "5" } }
```

```
{ "id": 5, "name": "Luis", "last_name": "Martínez" }
```

```
{ "index": { "_index": "alumnos", "_id": "7" } }
```

```
{ "id": 7, "name": "Sofía", "last_name": "Ramírez" }
```

```
{ "index": { "_index": "alumnos", "_id": "8" } }
```

```
{ "id": 8, "name": "Pedro", "last_name": "Hernández" }
```

,

Podemos comprobar que efectivamente se ha creado con una sencilla consulta:

Hagamos una consulta para ahora para ver los datos insertados:

```
curl -X GET "http://IP-SERVER-ELASTIC:9200/alumnos/_search?pretty"
```

ENTREGABLE PARTE 4: Captura de pantalla de la consola del cluster Hadoop con el resultado la consulta.

```
{
  "errors": false,
  "took": 76,
  "items": [
    {
      "index": "alumnos",
      "id": "3",
      "version": 1,
      "result": "created",
      "shards": {
        "total": 2,
        "successful": 1,
        "failed": 0,
        "seq_no": 1,
        "primary_term": 1,
        "status": 201
      }
    },
    {
      "index": "alumnos",
      "id": "4",
      "version": 1,
      "result": "created",
      "shards": {
        "total": 2,
        "successful": 1,
        "failed": 0,
        "seq_no": 2,
        "primary_term": 1,
        "status": 201
      }
    },
    {
      "index": "alumnos",
      "id": "5",
      "version": 1,
      "result": "created",
      "shards": {
        "total": 2,
        "successful": 1,
        "failed": 0,
        "seq_no": 3,
        "primary_term": 1,
        "status": 201
      }
    },
    {
      "index": "alumnos",
      "id": "6",
      "version": 1,
      "result": "created",
      "shards": {
        "total": 2,
        "successful": 1,
        "failed": 0,
        "seq_no": 4,
        "primary_term": 1,
        "status": 201
      }
    },
    {
      "index": "alumnos",
      "id": "7",
      "version": 1,
      "result": "created",
      "shards": {
        "total": 2,
        "successful": 1,
        "failed": 0,
        "seq_no": 5,
        "primary_term": 1,
        "status": 201
      }
    }
  ]
}

jbdmadrid@cluster-practica-hadoop-m:~$
jbdmadrid@cluster-practica-hadoop-m:~$
jbdmadrid@cluster-practica-hadoop-m:~$ curl -X GET "http://10.128.0.12:9200/alumnos/_search?pretty"
{
  "took": 103,
  "timed_out": false,
  "shards": {
    "total": 1,
    "successful": 1,
    "skipped": 0,
    "failed": 0
  },
  "hits": {
    "total": {
      "value": 6,
      "relation": "eq"
    },
    "max_score": 1.0,
    "hits": [
      {
        "index": "alumnos",
        "id": "6",
        "score": 1.0,
        "source": {
          "title": "New Document",
          "content": "This is a new document for the master class",
          "tag": [
            "general",
            "testing"
          ]
        }
      },
      {
        "index": "alumnos",
        "id": "3",
        "score": 1.0,
        "source": {
          "id": 3,
          "name": "Carlos",
          "last_name": "González"
        }
      },
      {
        "index": "alumnos",
        "id": "4",
        "score": 1.0,
        "source": {
          "id": 4,
          "name": "Maria",

```

```
{
  "_index" : "alumnos",
  "_id" : "3",
  "_score" : 1.0,
  "_source" : {
    "id" : 3,
    "name" : "Carlos",
    "last_name" : "González"
  }
},
{
  "_index" : "alumnos",
  "_id" : "4",
  "_score" : 1.0,
  "_source" : {
    "id" : 4,
    "name" : "María",
    "last_name" : "López"
  }
},
{
  "_index" : "alumnos",
  "_id" : "5",
  "_score" : 1.0,
  "_source" : {
    "id" : 5,
    "name" : "Luis",
    "last_name" : "Martínez"
  }
},
{
  "_index" : "alumnos",
  "_id" : "7",
  "_score" : 1.0,
  "_source" : {
    "id" : 7,
    "name" : "Sofía",
    "last_name" : "Ramírez"
  }
},
{
  "_index" : "alumnos",
  "_id" : "8",
  "_score" : 1.0,
  "_source" : {
    "id" : 8,
    "name" : "Pedro",
    "last_name" : "Hernández"
  }
}
]
}
```

jbdmadrid@cluster-practica-hadoop-m:~\$

PARTE 5 - Opcional. KIBANA!

Para esta parte, la idea es que explores Kibana y hagas un sencillo Dashboard, con el objetivo de que conozcas la herramienta y veas sus posibilidades.

Para ello:

En nuestro navegador, visitemos: http://IP_ELASTIC_SERVER:5601

En el menú izquierdo, en **Analitics**, hacemos click en **Dashboards**.

Hacemos click en **Create Dataview**, donde debemos seleccionar el index alumnos (hay que escribirlo). Y tras ello, hacemos click sobre **Create Dashboard y Create Visualization**

Una vez estemos en la pantalla del dashboard, podremos elegir una gran variedad de tipos de gráficos, visualizaciones etc. Solo queda explorar y probar algunas de las diferentes opciones!

ENTREGABLE 5: Opcional. Captura de pantalla de la consola de Kibana con alguna visualización sencilla.

