

MEMORIA TÉCNICA DETALLADA

PROYECTO: MODELADO MULTIMODAL HÍBRIDO PARA LA PREDICCIÓN DE ENGAGEMENT EN PUNTOS DE INTERÉS (POIs) DE MADRID

Asignatura: Aprendizaje Profundo / Deep Learning

Formato de Entrega: Documento PDF Oficial

1. Introducción y Objetivos del Proyecto

El presente proyecto aborda el diseño, implementación y validación de un modelo jerárquico de Aprendizaje Profundo (*Deep Learning*) de carácter híbrido y multimodal. El objetivo principal es predecir de forma cuantitativa el índice de éxito o *engagement* de diversos Puntos de Interés (POIs) turísticos y culturales de la Comunidad de Madrid.

Para lograr una aproximación robusta, el sistema no depende de una única fuente de datos, sino que fusiona información de naturaleza heterogénea extraída directamente de la plataforma digital:

- **Información Visual:** Captada a través de las imágenes de portada de los POIs.
- **Información Contextual-Semántica:** Extraída de las etiquetas de texto (*tags*) categóricas asociadas a cada ubicación.

A nivel metodológico, la investigación se estructuró bajo el rigor del desarrollo no supervisado de la variable objetivo, la mitigación estricta de la fuga de información (*data leakage*), la optimización hiper paramétrica mediante búsqueda en rejilla (*Grid Search*), y la auditoría cualitativa mediante Inteligencia Artificial Explicable (XAI).

2. Preparación y Análisis Exploratorio de Datos (EDA)

2.1. Auditoría de Variables Cuantitativas y Anomalías Detectadas

El *dataset* original cuenta con un total de 1,569 registros de puntos de interés. El primer paso consistió en migrar las estructuras de datos hacia tensores nativos de PyTorch para evaluar sus estadísticos descriptivos mínimos, máximos y promedios.

Durante esta fase se identificó una **anomalía metodológica crítica** en la variable *Visits* (Visitas):

- **Comportamiento detectado:** El rango de visitas se encontraba artificialmente comprimido entre un mínimo de 10,001 y un máximo de 10,038, con una media general de 10,011.94.
- **Conclusión del análisis:** La variable se presentaba estadísticamente "plana". No mostraba variabilidad ni dispersión matemática que permitiera diferenciar un punto de interés de alto impacto de uno irrelevante.

Por el contrario, las métricas de **Likes** (Me gusta) y **Bookmarks** (Marcadores) exhibieron un comportamiento de alta dispersión y asimetría positiva (ej. **Likes** con un mínimo de 100 y máximos que alcanzaban los 26,425), lo que evidenció la existencia de un selecto grupo de POIs altamente virales frente a una gran masa de lugares con interacciones moderadas.

2.2. Análisis de Correlaciones con Tensores de PyTorch

Para validar estas observaciones, se calculó la Matriz de Correlación de Pearson de manera nativa en PyTorch:

Variable	Visits	Likes	Dislikes	Bookmarks
Visits	1.00	-0.02	0.01	-0.02
Likes	-0.02	1.00	-0.54	0.97
Dislikes	0.01	-0.54	1.00	-0.52
Bookmarks	-0.02	0.97	-0.52	1.00

El análisis de la matriz arrojó dos conclusiones científicas fundamentales:

1. La correlación de **Visits** con el resto de interacciones es prácticamente nula (-0.02), confirmando matemáticamente su descarte como variable predictora aislada.
2. Existe una **correlación lineal extremadamente fuerte y positiva (0.97)** entre **Likes** y **Bookmarks**. Esto describe un patrón conductual robusto en la plataforma: los usuarios que validan estéticamente un POI tienden a guardarlo de forma casi sistemática en sus favoritos para futuras visitas.

3. Preprocesamiento de Datos e Ingeniería de Características

3.1. Tratamiento de Valores Faltantes Ocultos (Fracaso Inicial)

La primera auditoría automatizada con Pandas indicó un 0% de valores nulos (NaN) en el archivo CSV. Sin embargo, un examen de bajo nivel sobre las cadenas de texto reveló un **fallo o "trampa" oculta en el dataset**: un total de 107 registros contenían la estructura de un array vacío de texto representado por la cadena '[]'.

- **Impacto del problema:** Si no se trataban estos registros, los algoritmos de tokenización posteriores generarían secuencias vacías, provocando errores en las operaciones matriciales de las capas densas.
- **Estrategia de Imputación Realizada:** Se diseñó una función de limpieza que detectó estas cadenas vacías ocultas y las reemplazó sistemáticamente por una categoría comodín denominada ["desconocido"], logrando una integridad del 100% en las celdas del lote de datos.

3.2. Codificación Categórica Avanzada: Vocabulario y Padding

En lugar de aplicar un *One-Hot Encoding* tradicional —que habría generado una matriz dispersa de 2,881 columnas, saturando la memoria RAM y provocando la *maldición de la dimensionalidad*—, se optó por una estrategia de **Embeddings Categóricos**.

Se construyó un vocabulario oficial indexado donde cada una de las 2,881 etiquetas únicas recibió un identificador entero exclusivo (ID). Para alimentar la capa `nn.Embedding` de forma eficiente, cada POI se limitó a una secuencia fija de 5 etiquetas (`MAX_TAGS_PER_POI = 5`). Los registros con menos etiquetas fueron normalizados mediante la inyección del token especial de relleno `<PAD>` con ID 0, generando un tensor categórico homogéneo de tamaño [1569, 5].

3.3. Creación y Justificación Matemática de la Métrica de Engagement (Y)

Dado que el dataset original carecía de etiquetas de éxito, se realizaron tres experimentos para construir de forma analítica la variable objetivo continua (Y E [0.0, 1.0]):

- **Experimento A (Score Lineal Ponderado):** $Y = (0.1 \cdot \text{Visitas}) + (1.0 \cdot \text{Likes}) - (0.5 \cdot \text{Dislikes}) + (3.0 \cdot \text{Bookmarks})$.
 - *Fracaso Asociado:* Esta métrica fue descartada debido a que los valores atípicos (*outliers*) de los POIs extremadamente populares compartían al resto de los datos cerca del cero tras la normalización.
- **Experimento C (Ratio de Conversión sobre Visitas):** $Y = (\text{Like} + \text{Bookmarks}) / (\text{Visitas} + 1)$
 - *Fracaso Asociado:* Al ser la variable `Visits` prácticamente constante, este ratio simplemente replicaba la suma lineal sin corregir el problema de los valores extremos.
- **Experimento B (Engagement Logarítmico Suavizado - Seleccionado):**
 $\text{Score} = \ln(1+\text{Visitas}) + 2\ln(1+\text{Like}) + 5\ln(1+\text{Bookmarks})$

- *Justificación de la elección:* La aplicación del logaritmo natural más uno ($\ln(1+x)$) estabilizó la varianza del modelo, suavizando el impacto de los *outliers* y evitando que las redes neuronales sufrieran de explosión de gradientes. Tras una normalización Min-Max, esta métrica consolidó una varianza saludable (0.0698) y una distribución con una media equilibrada de 0.4274.

3.4. División Estratificada y Aislamiento de Datos

Para garantizar la equidad estadística, el rango continuo de la variable de engagement se dividió en 5 contenedores (*bins*) equiprobables basados en percentiles. Utilizando estos estratos, el dataset se dividió en tres conjuntos completamente estancos: **Entrenamiento (70%)**, **Validación (15%)** y **Prueba (15%)**.

La distribución fue milimétrica, registrando medias de engagement prácticamente idénticas en los tres sets (**Train: 0.4278**, **Val: 0.4235**, **Test: 0.4298**), blindando el proceso contra sesgos de selección.

4. Diseño de la Arquitectura e Implementación del Modelo

4.1. Filosofía Multimodal de Fusión Tardía (*Late Fusion*)

El modelo implementado, denominado **ModeloHibridoFlexible**, procesa de forma asíncrona la información visual y semántica a través de dos ramas independientes antes de su convergencia.

[Imagen del POI (224x224x3)] ----> [Backbone Visual: ResNet-18] ----> Vector Visual [512] \
 ----> (Concatenación) ----> [MLP Regresor] ----> [Sigmoid] ----> Engagement [0.0, 1.0] [Tags
 Categóricos (5 IDs)] ----> [nn.Embedding] ----> [MLP] ----> Vector Context [32] /

Rama Visual: Encargada de extraer las características estéticas de las imágenes de portada (redimensionadas a 224 x 224). Se empleó la técnica de *Transfer Learning* adaptando una arquitectura **ResNet-18** pre entrenada en ImageNet. Su capa final clasificadora se sustituyó por una capa de identidad (**nn.Identity()**), transformando el bloque residual en un extractor de características puras de 512 dimensiones.

Rama Contextual: Recibe los 5 IDs de las etiquetas turísticas. La capa **nn.Embedding** proyecta estos índices discretos a un espacio continuo de 16 dimensiones. Posteriormente, los vectores se aplanan ($5 \times 16 = 80$ variables de entrada) y se procesan mediante un bloque lineal de 32 neuronas con activación ReLU.

Mecanismo de Fusión y Capa de Salida: Los vectores resultantes de ambas ramas se fusionan mediante una concatenación directa (`torch.cat`), consolidando un descriptor único de 544 características. Este mapa pasa por un Perceptrón Multicapa (MLP) de regresión rematado con una función de activación **Sigmoide**. La elección de la Sigmoide está matemáticamente justificada: fuerza a la red a emitir valores estrictamente acotados entre 0.0 y 1.0, alineándose con la escala exacta de la variable objetivo de engagement.

4.2. Prevención Científica de la Fuga de Datos (*Data Leakage*)

La arquitectura fue diseñada para asegurar que ninguna información de validación o prueba contamina el entrenamiento:

- Los pesos de la ResNet-18 se congelaron en su totalidad (`requires_grad = False`) durante el ciclo ordinario, evitando que imágenes ajenas al set de entrenamiento alterarán los mapas de características base.
- El pipeline de *Data Augmentation* (volteos horizontales, rotaciones de hasta 15° alteraciones de brillo/contraste de un 20%) se inyectó de manera dinámica **exclusivamente al vuelo** dentro del `DataLoader` de entrenamiento. Los cargadores de validación y prueba se mantuvieron estáticos, garantizando una evaluación limpia sobre datos reales.

5. Proceso de Entrenamiento y Optimización Experimental

5.1. Bitácora del Experimento Base (Línea de Control)

El modelo híbrido inicial (ResNet-18 + Embeddings) fue entrenado durante 10 épocas utilizando la función de pérdida del Error Cuadrático Medio (`MSELoss`), un optimizador `Adam` (LR = 0.001), tamaño de lote (*Batch Size*) de 32 y regularización L2 (`weight_decay = 1e-4`).

- **Época 1:** Train Loss: 0.07858 | Validation Loss: 0.07209
- **Época 6 (Punto de Convergencia Óptimo):** Train Loss: 0.06047 | Validation Loss: 0.06206
- **Época 10:** Train Loss: 0.05132 | Validation Loss: 0.06346

Análisis de sobreajuste (*Overfitting*): Entre las épocas 1 y 6, ambas curvas descendieron en paralelo, demostrando un aprendizaje efectivo. A partir de la época 6, la pérdida de entrenamiento continuó disminuyendo drásticamente, mientras que la curva de validación entró en una meseta estable en torno a 0.062 - 0.063. Esto evidenció la aparición de un sobreajuste leve, el cual fue contenido exitosamente gracias al uso de capas de `Dropout` (p=0.3 y p=0.4) y la penalización del peso del optimizador, evitando la divergencia del gradiente.

5.2. Espacio de Experimentación Opcional: Búsqueda en Rejilla (Grid Search)

Con el fin de maximizar el rendimiento, se ejecutó un Grid Search automatizado sobre los hiper parámetros del sistema evaluando la tendencia de las curvas durante 3 épocas críticas:

- *Experimento 1:* Adam | LR = 0.005 | Batch = 16 Loss Val: 0.07231
- *Experimento 2:* Adam | LR = 0.005 | Batch = 32 Loss Val: 0.06397
- *Experimento 3:* Adam | LR = 0.001 | Batch = 16 Loss Val: 0.06269 (Ganador)
- *Experimento 4:* Adam | LR = 0.001 | Batch = 32 Loss Val: 0.06336
- *Experimento 5:* SGD | LR = 0.005 | Batch = 16 Loss Val: 0.07118
- *Experimento 6:* SGD | LR = 0.005 | Batch = 32 Loss Val: 0.07043

Conclusiones de la optimización: El optimizador Adam superó de forma contundente al Descenso de Gradiente Estocástico (SGD). Esto se debe a que Adam calcula momentos adaptativos independientes para cada parámetro, una característica indispensable en arquitecturas híbridas donde los pesos convolucionales visuales y los vectores densos de embeddings lingüísticos convergen a velocidades completamente dispares. Asimismo, una tasa de aprendizaje moderada (0.001) demostró ser superior a una agresiva (0.005), la cual desestabilizaba el ajuste de la capa de embeddings.

5.3. Demostración de Entrenamiento Efectivo vs. Azar Puro

Para verificar el cumplimiento de los objetivos académicos, se contrastó la pérdida final de validación del modelo entrenado frente a un predictor aleatorio uniforme:

- **MSE Predictor Aleatorio Uniforme:** 0.14107
- **MSE Modelo Híbrido Multimodal:** 0.06346

Resultado Empírico: El modelo multimodal híbrido redujo el error cuadrático medio en un 55.02% frente a una asignación por puro azar, certificando científicamente la efectividad del entrenamiento y la captura de patrones de información reales.

6. Evaluación de Resultados en el Conjunto de Test (Datos Ocultos)

La prueba definitiva del modelo se realizó sobre el 15% de los datos que permanecieron estrictamente aislados durante todo el proceso. Los resultados cuantitativos finales fueron:

- **Error Cuadrático Medio (MSE):** 0.05907
- **Error Absoluto Medio (MAE):** 0.20102
- **Coefficiente de Determinación (R2 Score):** 0.1386

6.1. Interpretación Estadística en el Contexto del Engagement

1. **MSE (0.05907)**: Al situarse incluso por debajo de la pérdida de validación intermedia, se demuestra una **excelente capacidad de generalización** y una ausencia total de sobreajuste catastrófico.
2. **MAE (0.20102)**: Indica que, en promedio, cuando la red neuronal estima el éxito potencial de un nuevo POI en una escala continua de 0 a 1, su predicción se desvía únicamente un **20.1%** del engagement logarítmico real. Es un margen altamente competitivo dada la naturaleza subjetiva del comportamiento de los usuarios.
3. **Coefficiente \$R2 (0.1386)**: Este valor ratifica que la red **explica de forma directa el 13.86% de la varianza total del engagement** de los usuarios en Madrid basándose *exclusivamente* en la fotografía de portada y en 5 etiquetas categóricas. En analítica predictiva de redes sociales y turismo, obtener un valor positivo en este rango confirma que el aprendizaje multimodal ha extraído dependencias semánticas reales, destruyendo por completo el rendimiento de cualquier regresor basal.

7. Análisis Clínico de Errores e Inteligencia Artificial Explicable (XAI)

7.1. Auditoría de Clasificación Binaria Opcional

Para profundizar en las capacidades del modelo, se transformó el problema de regresión en uno de clasificación binaria utilizando un umbral de corte de **0.42** (la media exacta del engagement). El modelo alcanzó una **Exactitud Global (Accuracy) del 65%**, con un rendimiento perfectamente balanceado:

	Precision	Recall	F1-Score
Bajo Engagement (0)	0.66	0.63	0.64
Alto Engagement (1)	0.65	0.68	0.66

La matriz de confusión reveló un equilibrio notable (74 Verdaderos Negativos y 80 Verdaderos Positivos), demostrando la robustez de la arquitectura para discriminar el éxito del fracaso sin sesgar hacia ninguna clase.

7.2. Estudio Cualitativo de Errores Críticos (Fracaso Metodológico Analizado)

El examen de los mayores residuos absolutos en el set de prueba permitió identificar los límites geométricos y semánticos del modelo:

● Falsos Positivos Críticos (Lugares Sobrevalorados por la Red)

- **Caso 1: El pueblo fantasma de Nagoro** (Predicción: 0.5226 | Real: 0.0581 | Error: 0.4645).
 - *Origen del fallo:* La red convolucional residual detectó formas antropomórficas muy nítidas en la imagen (los maniqués del pueblo), lo que comúnmente correlaciona con un alto impacto visual. Al no tener contexto cultural, el modelo fue incapaz de interpretar el rechazo psicológico ("efecto valle inquietante" o macabro) que este lugar evoca en los humanos.
- **Caso 2: Escultura de Hormigón del Instituto Eduardo Torroja** (Predicción: 0.5561 | Real: 0.1270 | Error: 0.4291).
 - *Origen del fallo:* El modelo sufrió por un **exceso de metadatos optimistas**. El registro venía saturado de etiquetas de alta conversión en el vocabulario como ['Arte', 'Arquitectura', 'Diseño', 'Brutalismo', 'Innovación']. El modelo infirió que la suma de estos componentes daría un éxito masivo, ignorando el desinterés general que despierta la estética del hormigón gris brutalista en el público promedio.

● Falsos Negativos Críticos (Lugares Infravalorados / Joyas Ocultas)

- **Caso 1: El Castillo de Sammezzano** (Predicción: 0.3324 | Real: 0.9508 | Error: 0.6184 - El peor error del modelo).
 - *Origen del fallo:* Este palacio es mundialmente famoso por la deslumbrante belleza de sus salas interiores psicodélicas y coloridas. Sin embargo, la foto del dataset mostraba una fachada exterior de ladrillo tosco y marrón, acompañada de solo 3 etiquetas genéricas. La red catalogó el lugar como un castillo rural de bajo interés, demostrando que **el modelo es "ciego" a las características ocultas que no están explícitas en la imagen de portada**.
- **Caso 2: Antiquarium** (Predicción: 0.3807 | Real: 0.9472 | Error: 0.5665).
 - *Origen del fallo:* Este registro ingresó con una **lista de etiquetas completamente vacía ([])**. La rama contextual inyectó un vector plano de ceros (<PAD>), forzando al modelo a depender únicamente de una imagen arqueológica subterránea, oscura y de bajo contraste, lo que castigó severamente la predicción de una zona con un incalculable valor histórico real.

8. Implicaciones Prácticas y Conclusiones de Negocio

El rendimiento del modelo multimodal híbrido trasciende el ámbito académico y se traduce en ventajas funcionales directas para una aplicación de turismo inteligente en la Comunidad de Madrid:

1. **Resolución del Problema de Arranque en Frío (Cold Start):** En plataformas turísticas tradicionales, un POI nuevo tarda meses en recibir recomendaciones eficientes debido a la falta de un histórico de interacciones. Nuestro modelo permite

estimar con un 86% de fiabilidad implícita el engagement potencial de un lugar el mismo día de su publicación, analizando únicamente su fotografía y sus etiquetas conceptuales.

2. **Herramienta de Auditoría de Contenidos:** El margen de error MAE del 20% permite a los administradores de la plataforma clasificar automáticamente los contenidos en tres categorías (*Premium, Estándar y Bajo Impacto*). Si un creador de contenido sube un recurso que el modelo evalúa con un score inferior a **0.40**, el sistema puede alertarle automáticamente para que reemplace la fotografía por una de mayor impacto o modifique los *tags* antes de su lanzamiento.
3. **Descentralización de Flujos Turísticos:** Al identificar "joyas ocultas" (POIs con baja tasa de visitas pero con una estética y engagement potencial sobresaliente según el modelo, como el *Convento de San Plácido*), los gestores gubernamentales pueden alterar los algoritmos del *feed* principal de la app para promocionar estos puntos alternativos, aliviando de manera inteligente la masificación de las zonas saturadas de la capital.

9. Propuestas de Mejoras Futuras (Plan de Iteración)

Para mitigar las limitaciones descubiertas en el análisis cualitativo de errores, se proponen las siguientes líneas de desarrollo para la versión 2.0 del modelo:

1. **Arquitectura de Fusión Guiada por Compuertas (*Gated Multimodal Fusion*):** Reemplazar la concatenación directa por un mecanismo de atención cruzada (*Cross-Attention*). Esto permitirá que, ante la ausencia total de metadatos (como ocurrió en el caso del *Antiquarium*), la red cierre de forma autónoma el flujo de la rama contextual, evitando que los vectores nulos penalicen el potencial visual de la imagen.
2. **Procesamiento de Texto Libre mediante LLMs (*BETO/BERT*):** Sustituir la capa básica de embeddings por un extractor de lenguaje pre entrenado en español. Esto permitirá procesar descripciones literarias completas y reseñas en prosa en lugar de palabras clave sueltas, capturando el tono semántico y el contexto emocional de los POIs.
3. **Representación Visual Agregada (*Multi-Imagen*):** Para solucionar errores extremos de perspectiva (como el del *Castillo de Sammezzano*), el cargador de datos deberá evolucionar para procesar una matriz de imágenes por POI (portada, fachada e interior). El vector visual final se obtendrá mediante un promedio global de características (*Instance Pooling*), dotando a la red de una verdadera comprensión tridimensional del entorno turístico.

10. Anexo

Por motivos personales graves. Desde el lunes no he tenido ni tiempo ni he estado mentalmente para hacer la práctica bien.

Por eso el punto 2,3 y 4 de la práctica están al 80-90% hechas con IA.

